



IF01

Informe del primer avance del Producto Integrador

Curso de Machine Learning

Asignación de datasets por grupo

Cada grupo (5 integrantes) trabaja un dataset distinto. Todos están en la carpeta dataset-01.

Grupo	Dataset	Archivo CSV	Variable objetivo
1	House Prices	01_house_prices_grupo1.csv	sale_price
2	California Housing	02_california_housing_grupo2.csv	median_house_value
3	Used Cars	03_used_cars_grupo3.csv	selling_price
4	Bike Sharing Demand	04_bike_sharing_grupo4.csv	count
5	Diamonds	05_diamonds_grupo5.csv	price
6	Laptop Prices	06_laptop_prices_grupo6.csv	price
7	Flight Ticket Prices	07_flight_prices_grupo7.csv	price
8	Employee Salary	08_employee_salary_grupo8.csv	annual_salary

Realizar los siguientes pasos

1. Cargar el CSV en Google Colab
2. Explorar la estructura (head, shape, info, describe) e identificar la variable objetivo
3. Detectar valores faltantes
4. Eliminar duplicados
5. Quitar columnas irrelevantes
6. Verificar tipos de datos
7. Detectar valores atípicos (outliers)
8. Separar variables numéricas y categóricas
9. Aplicar One-Hot Encoding
10. Visualizar la variable objetivo
11. Guardar el dataset preparado

Enunciado del caso

Una inmobiliaria necesita estimar el precio de venta de una vivienda en función de sus características físicas, su ubicación y su estado de mantenimiento.

Archivo: 01_house_prices_grupo1.csv

Rol de cada columna

Columna(s)	Rol	Por qué
house_id, listing_address	Irrelevantes	Identificadores administrativos, no influyen en el precio
sale_date	Irrelevante (paso 6)	Fecha de venta como texto, no aporta al modelo
lot_area, year_built, bedrooms, bathrooms, garage_cars, overall_qual	Predictoras numéricas	Características físicas que afectan el valor
neighborhood, house_style, central_air, sale_condition	Predictoras categóricas	Atributos cualitativos que diferencian propiedades
sale_price	Objetivo (y)	Precio de venta de la vivienda — lo que se quiere predecir

Enunciado del caso

Un gobierno regional necesita estimar el valor mediano de las viviendas por bloque poblacional, en función de los ingresos, la ubicación y características demográficas.

Archivo: 02_california_housing_grupo2.csv

Rol de cada columna

Columna(s)	Rol	Por qué
block_id, internal_code	Irrelevantes	Identificadores administrativos sin valor predictivo
record_date	Irrelevante (paso 6)	Fecha del registro como texto, no aporta al modelo
median_income, housing_median_age, total_rooms, total_bedrooms, population, households, latitude, longitude	Predictoras numéricas	Variables demográficas y geográficas relacionadas con el precio
ocean_proximity	Predictora categórica	La cercanía al océano influye fuertemente en el valor
median_house_value	Objetivo (y)	Valor mediano de las viviendas del bloque — lo que se quiere predecir

Enunciado del caso

Una concesionaria necesita estimar el precio de venta de autos usados según su antigüedad, kilometraje, combustible, transmisión y características técnicas.

Archivo: 03_used_cars_grupo3.csv

Rol de cada columna

Columna(s)	Rol	Por qué
vehicle_id, registration_number	Irrelevantes	Identificadores administrativos del vehículo
car_name, mileage, engine	Tipos a corregir (paso 6)	Texto con marca, unidades 'kmpl' y 'CC' deben extraerse a número
year, km_driven, max_power_bhp	Predictoras numéricas	Variables técnicas que afectan el valor del auto
fuel, seller_type, transmission, owner	Predictoras categóricas	Atributos del vehículo y de la transacción
selling_price	Objetivo (y)	Precio de venta del auto — lo que se quiere predecir

Grupo 4 — Bike Sharing Demand

Enunciado del caso

Una empresa de bicicletas compartidas necesita estimar la cantidad de alquileres por hora en función del clima, la fecha y el momento del día.

Archivo: 04_bike_sharing_grupo4.csv

Rol de cada columna

Columna(s)	Rol	Por qué
record_id, instant	Irrelevantes	Identificadores secuenciales sin valor predictivo
date	Irrelevante (paso 6)	Fecha como texto; ya hay año y mes en otras columnas
year, month, hour, holiday, workingday, temp_celsius, humidity, windspeed	Predictoras numéricas	Tiempo, clima y calendario afectan la demanda
season, weekday, weather	Predictoras categóricas	Estación, día de la semana y tipo de clima
count	Objetivo (y)	Cantidad de alquileres registrados — lo que se quiere predecir

Enunciado del caso

Una joyería necesita estimar el precio de los diamantes en función de su quilataje, calidad de talla, color, claridad y dimensiones físicas.

Archivo: 05_diamonds_grupo5.csv

Rol de cada columna

Columna(s)	Rol	Por qué
diamond_id, supplier_code	Irrelevantes	Identificadores administrativos del diamante
certified_date	Irrelevante (paso 6)	Fecha de certificación como texto, no aporta al modelo
carat, depth, table, x_dim, y_dim, z_dim	Predictoras numéricas	Quilataje y dimensiones físicas que determinan el valor
cut, color, clarity	Predictoras categóricas	Calidad de talla, color y claridad — estándares 4C de joyería
price	Objetivo (y)	Precio del diamante — lo que se quiere predecir

Grupo 6 — Laptop Prices

Enunciado del caso

Una tienda de tecnología necesita estimar el precio de venta de una laptop en función de sus características técnicas, la marca y el tipo de equipo.

Archivo: 06_laptop_prices_grupo6.csv

Rol de cada columna

Columna(s)	Rol	Por qué
laptop_id, serial_number	Irrelevantes	Identificadores administrativos del equipo
listed_date	Irrelevante (paso 6)	Fecha de publicación como texto, no aporta al modelo
ram_gb, storage_gb, screen_size_in, weight_kg, battery_hours	Predictoras numéricas	Especificaciones técnicas que determinan el rendimiento y el precio
brand, cpu_brand, gpu_brand, laptop_type, os	Predictoras categóricas	Atributos cualitativos que diferencian a los equipos
price	Objetivo (y)	Precio de venta de la laptop — lo que se quiere predecir

Grupo 7 — Flight Ticket Prices

Enunciado del caso

Una aerolínea necesita estimar el precio de un ticket aéreo en función de la ruta, la aerolínea, la anticipación de compra y la clase del vuelo.

Archivo: 07_flight_prices_grupo7.csv

Rol de cada columna

Columna(s)	Rol	Por qué
flight_id, booking_reference	Irrelevantes	Identificadores administrativos del vuelo y la reserva
departure_date	Irrelevante (paso 6)	Fecha de salida como texto, no aporta al modelo
duration_minutes, days_left, stops	Predictoras numéricas	Duración del vuelo, anticipación de compra y escalas que afectan la tarifa
airline, source_city, destination_city, travel_class, departure_time_slot	Predictoras categóricas	Ruta, aerolínea, clase y franja horaria del vuelo
price	Objetivo (y)	Precio del ticket aéreo — lo que se quiere predecir

Grupo 8 — Employee Salary

Enunciado del caso

Una empresa de tecnología necesita estimar el salario anual de un empleado en función de su experiencia, su cargo, su nivel educativo y el área en la que trabaja.

Archivo: 08_employee_salary_grupo8.csv

Rol de cada columna

Columna(s)	Rol	Por qué
employee_id, employee_code	Irrelevantes	Identificadores administrativos del empleado
hire_date	Irrelevante (paso 6)	Fecha de contratación como texto, no aporta al modelo
years_experience, age, hours_per_week, num_certifications	Predictoras numéricas	Experiencia, edad, carga laboral y certificaciones que influyen en el salario
job_title, department, education_level, company_size, work_mode	Predictoras categóricas	Cargo, área, nivel educativo, tamaño de empresa y modalidad de trabajo
annual_salary	Objetivo (y)	Salario anual del empleado — lo que se quiere predecir

Entregable

Notebook de Google Colab con los 11 pasos aplicados al dataset asignado, ejecutado sin errores.

Primera celda del notebook

Número de grupo, dataset elegido y nombres de los 5 integrantes.

Se presenta: Sabado 05 de septiembre en el horario acordado con el docente

Rúbrica de calificación

Nota final = 70% grupal + 30% individual | Total: 20 pts

Parte grupal (14 pts) — misma nota para los 5 integrantes

Bloque	Criterio	Pts
A. Conocer	Identificación de variable objetivo y rol de cada columna	3
B. Limpiar	Nulos, duplicados, columnas irrelevantes, tipos, outliers	5
C. Transformar	Separación de tipos y One-Hot Encoding	2
D. Validar y guardar	Visualización + dataset exportado	2
—	Notebook ejecuta sin errores, ordenado y documentado	2

Parte individual (6 pts) — una pregunta por integrante en la sustentación

Respuesta	Pts
No responde o incorrecta	0
Responde con dificultad, idea parcial	2
Responde correctamente	4
Responde con claridad y dominio	6